Vue d’architecture fonctionnelle

AI-Assisted Configurable Web Scraping Platform

Spring Boot · Quarkus · Python
Playwright · PostgreSQL · MongoDB · Redis

Configuration & orchestration

Création de jobs
Définition d’un job : URL cible, schéma, paramètres de crawling et fréquence, via API REST.
JobController · CreateJobRequest · JobService

Cycle de vie & états
Machine à états (créé, en file, en cours, pause, terminé, échoué) avec transitions contrôlées et historique.
JobStatus · Job · JobStatsResponse

Planification cron
Exécutions récurrentes planifiées via l’ordonnanceur Quartz.
JobScheduler · QuartzJobScheduler

Déclenchement webhook
Lancement sur événement externe avec credentials signés et vérification de signature.
WebhookTriggerService · WebhookSignatureVerifier

Schéma d’extraction
Champs à extraire, types de données, règles de validation et de transformation.
ExtractionSchema · SchemaField

Assistant LLM schéma
Génération du schéma par prompt en langage naturel ; validation assistée.
PromptAssistantService · SchemaValidatorService

Auto-réparation sélecteurs
L’IA détecte un sélecteur cassé (changement de layout) et propose une correction.
SelectorHealer · SelectorHealerPrompt

Templates de jobs
Duplication et modèles prédéfinis par secteur (e-commerce, annonces, actualités).
Template · TemplateCategory

Éditeur visuel no-code
Sélection point-and-click avec durcissement et sanitisation des sélecteurs.
VisualSelectorController · SelectorHardener

Planificateur d’actions
Séquences pré-extraction (clic, scroll, saisie) résolues par IA.
ActionPlannerService · ActionSelectorResolver

Mode test / dry-run
Sondage du site sur échantillon avant lancement complet.
SiteProbeService · SiteProbeRequest

Acquisition & navigation

Rendu headless
Rendu complet des pages dynamiques (JS) via navigateur sans interface.
PlaywrightBrowser · PlaywrightPageRenderer

Moteur alternatif
Support Selenium et fabrique de navigateurs interchangeable.
SeleniumBrowser · BrowserFactory

Crawling distribué
File d’attente d’URL distribuée avec déduplication et coordination.
DistributedCrawlFrontier · DistributedCrawlCoordinator

Récolte de liens
Extraction, normalisation et filtrage des liens internes (include/exclude).
LinkHarvester · UrlNormalizer · UrlFilter

Sitemap & fichiers
Découverte automatique du sitemap et des fichiers du site.
SitemapSeeder · SiteFileDiscoverer

Pagination classique
Numérotée, par paramètre d’URL et bouton « suivant ».
NumberedPagination · UrlParamPagination · NextButtonPagination

Pagination dynamique
Scroll infini, « charger plus » et détection LLM des SPA.
InfiniteScrollPagination · LlmPaginationDetector

Extraction sélecteurs
Extraction par CSS, XPath et expressions régulières.
CssExtractor · XPathExtractor · RegexExtractor

Extraction sémantique IA
Le LLM identifie les données pertinentes et retourne du JSON structuré.
LlmExtractor · LlmExtractionService

Sessions & login
Sessions authentifiées, cookies, connexion par formulaire ou import.
TieredSessionStore · FormLoginStrategy

Analyse du site cible
Détection des protections et score de difficulté (facile/moyen/difficile).
SiteProtectionDetectorRegistry · ScrapingDifficultyScorer

Contournement anti-bot

Rotation de proxies
Pool avec stratégies round-robin, aléatoire, moins-utilisé et plus-rapide.
ProxyPoolService · ProxyRotationStrategy

Proxies géolocalisés
Sélection par pays/région pour contenu géo-restreint.
ProxyCountryStat · CountryCodeNormalizer

Santé du pool
Health-checks, rafraîchissement et sources multiples de proxies.
ProxyHealthChecker · ProxySourceRegistry

Empreinte HTTP/TLS
Variation des en-têtes et empreinte TLS (JA3/JA4) cohérente.
ConsistencyProfile · ConsistencyProfileFactory

Mode furtif
Masquage webdriver, plugins factices, canvas, WebGL, WebRTC.
PlaywrightStealthProfile · StealthScriptLoader

Comportement humain
Souris (Bézier), scroll, frappe rythmée pour tromper la détection comportementale.
BezierMouseMotion · Humanizer · TypingRhythm

CAPTCHA — reCAPTCHA
Résolution reCAPTCHA v2 (image) et v3 (score natif).
RecaptchaV2ImageSolver · RecaptchaV3NativeSolver

CAPTCHA — autres
hCaptcha, Turnstile, FunCaptcha, GeeTest, Rotate.
HcaptchaImageSolver · TurnstileSolver · GeetestSliderSolver

CAPTCHA — LLM & externe
Solveur vision LLM, fallback, 2Captcha et intervention humaine.
LlmImageCaptchaSolver · TwoCaptchaSolver

Détection côté proxy
Détection Cloudflare/DataDome au niveau du proxy avec suivi de statut.
CloudflareProxyDetector · ProxyAntiBotStatus

Bypass CDN via DNS
Résolution de l’IP d’origine derrière un CDN par historique DNS.
OriginIpResolver · CdnIpRangeRegistry · CidrMatcher

Traitement & qualité

Pipeline ETL
Étapes d’extraction/transformation/chargement chaînées et configurables.
EtlPipelineRunner · EtlConfig · EtlStepRegistry

Nettoyage HTML
Suppression des balises résiduelles, espaces et caractères parasites.
HtmlStripperStep · TrimWhitespaceStep

Déduplication
Suppression des doublons par clés configurables.
DeduplicateStep

Normalisation formats
Dates (ISO 8601), prix/numérique, mapping de valeurs (enum).
DateNormalizerStep · PriceNormalizerStep · EnumNormalizerStep

Valeurs manquantes
Stratégies : ignorer, défaut, interpolation, marquage.
MissingValueHandlerStep

Validation & qualité
Règles par champ (type, plage, regex) et score de qualité.
ValidateFieldsStep · QualityReport · ValidationRule

Enrichissement IA
KPI, classification et catégorisation automatiques.
AiEnrichmentStep · ClassificationStep

NER & résumé
Extraction d’entités nommées et résumé automatique.
NerStep · SummarizationStep

Détection d’anomalies
Repérage IA des valeurs aberrantes (prix négatifs, dates futures).
AnomalyDetectionStep

Anonymisation PII
Masquage RGPD des données personnelles détectées.
PiiAnonymizationStep

Export multi-cibles
CSV, JSON, SQL/NoSQL ; stockage et téléchargement.
ExportService · ExportStorageService · ScrapeResult

Supervision & résilience

Dashboard temps réel
Vue des jobs, taux de succès, volume ; santé système.
MonitoringController · SystemHealthService

Métriques
Performance, flux, LLM et CAPTCHA.
PerformanceService · StreamMetrics · LlmMetrics

Notifications
Alertes configurables diffusées en temps réel (SSE).
NotificationService · NotificationBroadcaster

Retry intelligent
Backoff exponentiel, jitter et conditions de reprise.
RetryExecutor · RetryPolicy

Circuit breaker
Désactivation temporaire d’un site/proxy en cas d’échecs répétés.
DomainCircuitBreaker · CircuitBreakerRegistry

Workers résilients
Auto-récupération et re-traitement via schedulers de recovery.
ScrapeWorkerPool · StreamRecoveryScheduler

Traitement distribué
Files et coordination via Redis Streams (consumer groups).
RedisStreamNames · StreamConfig · ConsumerIdentity

Reprise ETL / crawl
Checkpoint et redémarrage à l’étape échouée.
EtlRecoveryScheduler · CrawlJoinRecoveryScheduler

Protection SSRF
Blocage des requêtes vers cibles internes non autorisées.
SsrfGuard

Observabilité LLM
Enregistrement des appels, issues et contexte.
LlmCallRecorder · LlmCallEntity

Coûts LLM par projet
Suivi de consommation et quota des modèles.
ProjectLlmUsageService · LlmRateLimitException

Gouvernance & conformité

Projets multi-membres
Espaces projet isolés avec membres, rôles et statistiques.
ProjectService · ProjectMember · ProjectRole

Invitations
Envoi et cycle de réponse aux invitations de projet.
ProjectInvitationService · InvitationStatus

Comptes utilisateurs
Gestion des profils, comptes et avatars.
UserService · AccountController

Authentification BFF
Tokens BFF avec refresh et filtre de sécurité.
AuthController · BffTokenService · SecurityFilter

RBAC
Contrôle d’accès par rôles (admin, opérateur, lecteur).
UserRole · SecurityConfigSettings

Chiffrement session
Chiffrement des sessions sensibles.
SessionCrypto

Audit trail
Journalisation de toutes les actions ; interception auto.
AuditLogService · AuditLogFilter · Auditable

Masquage sensible
Masquage des données sensibles dans les logs.
SensitiveDataMasker

Respect robots.txt
Lecture et application des règles du fichier robots.
RobotsTxtGate

Conformité RGPD
Anonymisation et journalisation de conformité.
PiiAnonymizationStep · AuditResource

Rétention & versioning
Versioning des données et politiques de conservation.
DataVersion · DataVersionService

Socle technique & DevOps

Architecture hexagonale
Découpage par feature en domain / application / infrastructure (ports & adapters).
*com.elyadata.feature.**

API normalisée
Réponses et pagination uniformes.
ApiResponse · PageMeta · Page

Gestion d’erreurs
Exceptions domaine et infra 4xx/5xx avec handlers dédiés.
ElyaScraperExceptionHandler · DomainException

Clients LLM
Chat et vision (Groq) avec parsing robuste des réponses.
GroqLlmChatClient · GroqVisionLlmClient · LlmResponseParser

Garde sécurité LLM
Protection anti-injection des entrées LLM.
LlmSecurityGuard · LlmSecurityGuardRules

Migrations Flyway
45 migrations versionnées du schéma relationnel.
V1… V45_*.sql

Indices de perf
Indices dédiés dashboard et performance.
V33 · V45_add_performance_indexes

Coordination Redis
Streams, files et locks distribués.
StreamConfig · RedisStreamNames

Tests unitaires
Couverture par composant (steps, extracteurs, proxies…).
**Test.java*

Tests d’intégration
Tests des contrôleurs REST.
**IT.java*

Tests E2E distribués
Scénarios crawl et scrape de bout en bout.
DistributedCrawlJobE2EIT · DistributedScrapeJobE2EIT